

ME731 - Métodos em Análise Multivariada

– Análise Fatorial I –

Prof. Carlos Trucíos
ctrucios@unicamp.br
ctruciosm.github.io

Instituto de Matemática, Estatística e Computação Científica,
Universidade Estadual de Campinas

Aula 13



Agenda I

- 1 Introdução
- 2 Motivação
- 3 Modelo Fatorial
- 4 Estimação

Introdução

Introdução

- **Caso 1:** suponha que estamos interessados em estudar o desenvolvimento humano dos países do mundo e que dispomos de um conjunto de variáveis econômicas, sociais e demográficas relacionadas com desenvolvimento humano.

Introdução

- **Caso 1:** suponha que estamos interessados em estudar o desenvolvimento humano dos países do mundo e que dispomos de um conjunto de variáveis econômicas, sociais e demográficas relacionadas com desenvolvimento humano. Uma pergunta interessante é se o desenvolvimento de um país pode ser explicado por um pequeno número de fatores tais que, conhecidos seus valores, poderíamos conhecer o conjunto de variáveis de cada país.

Introdução

- **Caso 1:** suponha que estamos interessados em estudar o desenvolvimento humano dos países do mundo e que dispomos de um conjunto de variáveis econômicas, sociais e demográficas relacionadas com desenvolvimento humano. Uma pergunta interessante é se o desenvolvimento de um país pode ser explicado por um pequeno número de fatores tais que, conhecidos seus valores, poderíamos conhecer o conjunto de variáveis de cada país.
- **Caso 2:** suponha que medimos, através de diversos testes, a capacidade mental de indivíduos para processar informação e resolver problemas.

Introdução

- **Caso 1:** suponha que estamos interessados em estudar o desenvolvimento humano dos países do mundo e que dispomos de um conjunto de variáveis econômicas, sociais e demográficas relacionadas com desenvolvimento humano. Uma pergunta interessante é se o desenvolvimento de um país pode ser explicado por um pequeno número de fatores tais que, conhecidos seus valores, poderíamos conhecer o conjunto de variáveis de cada país.
- **Caso 2:** suponha que medimos, através de diversos testes, a capacidade mental de indivíduos para processar informação e resolver problemas. Será que existem fatores, não diretamente observáveis, que explicam os resultados observados?

Introdução

- **Caso 1:** suponha que estamos interessados em estudar o desenvolvimento humano dos países do mundo e que dispomos de um conjunto de variáveis econômicas, sociais e demográficas relacionadas com desenvolvimento humano. Uma pergunta interessante é se o desenvolvimento de um país pode ser explicado por um pequeno número de fatores tais que, conhecidos seus valores, poderíamos conhecer o conjunto de variáveis de cada país.
- **Caso 2:** suponha que medimos, através de diversos testes, a capacidade mental de indivíduos para processar informação e resolver problemas. Será que existem fatores, não diretamente observáveis, que explicam os resultados observados? (esses fatores seriam a *inteligência*, por exemplo).

Introdução

- **Caso 1:** suponha que estamos interessados em estudar o desenvolvimento humano dos países do mundo e que dispomos de um conjunto de variáveis econômicas, sociais e demográficas relacionadas com desenvolvimento humano. Uma pergunta interessante é se o desenvolvimento de um país pode ser explicado por um pequeno número de fatores tais que, conhecidos seus valores, poderíamos conhecer o conjunto de variáveis de cada país.
- **Caso 2:** suponha que medimos, através de diversos testes, a capacidade mental de indivíduos para processar informação e resolver problemas. Será que existem fatores, não diretamente observáveis, que explicam os resultados observados? (esses fatores seriam a *inteligência*, por exemplo).

Fonte: Análisis de Datos Multivariantes (Daniel Peña, 2002)

Introdução

- Análise Fatorial tem como objetivo explicar um conjunto de variáveis através de um pequeno número de variáveis latentes (chamadas de *fatores*).

Introdução

- Análise Fatorial tem como objetivo explicar um conjunto de variáveis através de um pequeno número de variáveis latentes (chamadas de *fatores*).
- Desde outro ponto de vista, análise fatorial tenta explicar a correlação de um conjunto de variáveis através de um número pequeno de fatores (veremos que ambos pontos de vista implicam no mesmo problema).

Introdução


- Análise Fatorial tem como objetivo explicar um conjunto de variáveis através de um pequeno número de variáveis latentes (chamadas de *fatores*).
- Desde outro ponto de vista, análise fatorial tenta explicar a correlação de um conjunto de variáveis através de um número pequeno de fatores (veremos que ambos pontos de vista implicam no mesmo problema).
- Embora as variáveis dependam de fatores, também estão sujeitas a perturbações aleatórias.

Introdução

- Análise Fatorial tem como objetivo explicar um conjunto de variáveis através de um pequeno número de variáveis latentes (chamadas de *fatores*).
- Desde outro ponto de vista, análise fatorial tenta explicar a correlação de um conjunto de variáveis através de um número pequeno de fatores (veremos que ambos pontos de vista implicam no mesmo problema).
- Embora as variáveis dependam de fatores, também estão sujeitas a perturbações aleatórias.
- Os fatores não são observados diretamente.


Introdução

Variáveis não observáveis?



Introdução

Variáveis não observáveis?



- Esse conceito é bastante comum em psicologia onde aquilo que queremos mensurar não é diretamente observável (*inteligência*, por exemplo).
- Entre as áreas nas quais esta técnica é utilizada temos: marketing, economia, finanças, ciência política, psicologia, etc.

Motivação

Motivação

Um estudo aplicado em crianças mede o desempenho delas em Espanhol (X_1), Português (X_2) e Inglês (X_3).

A Matriz de correlação entre as três variáveis é dada por:

$$\begin{pmatrix} 1 & 0.83 & 0.78 \\ 0.83 & 1 & 0.67 \\ 0.78 & 0.67 & 1 \end{pmatrix}$$

Motivação

Um estudo aplicado em crianças mede o desempenho delas em Espanhol (X_1), Português (X_2) e Inglês (X_3).

A Matriz de correlação entre as três variáveis é dada por:

$$\begin{pmatrix} 1 & 0.83 & 0.78 \\ 0.83 & 1 & 0.67 \\ 0.78 & 0.67 & 1 \end{pmatrix}$$

E se existir um fator (latente) que nos ajude a entender essa correlação toda?

Motivação

Se existir esse fator, podemos reescrever as três variáveis da seguinte forma:

$$X_1 = \lambda_1 f + u_1, \quad X_2 = \lambda_2 f + u_2, \quad X_3 = \lambda_3 f + u_3,$$

em que

Motivação

Se existir esse fator, podemos reescrever as três variáveis da seguinte forma:

$$X_1 = \lambda_1 f + u_1, \quad X_2 = \lambda_2 f + u_2, \quad X_3 = \lambda_3 f + u_3,$$

em que

- f é um *fator comum* não observável,
- $\lambda_1, \lambda_2, \lambda_3$ são *cargas fatoriais*,
- u_1, u_2, u_3 são perturbações aleatórias.

f pode ser entendido como uma *habilidade geral* e u_i terá uma variabilidade pequena se x_i estiver estreitamente relacionada com essa *habilidade geral*.

Motivação

Se existir esse fator, podemos reescrever as três variáveis da seguinte forma:

$$X_1 = \lambda_1 f + u_1, \quad X_2 = \lambda_2 f + u_2, \quad X_3 = \lambda_3 f + u_3,$$

em que

- f é um *fator comum* não observável,
- $\lambda_1, \lambda_2, \lambda_3$ são *cargas fatoriais*,
- u_1, u_2, u_3 são perturbações aleatórias.

f pode ser entendido como uma *habilidade geral* e u_i terá uma variabilidade pequena se x_i estiver estreitamente relacionada com essa *habilidade geral*.

$$\mathbb{V}(\mathbf{X}) = \Lambda \mathbb{V}(f) \Lambda' + \mathbb{V}(\mathbf{u}) + \mathbb{Cov}(\Lambda f, \mathbf{u}) + \mathbb{Cov}(\mathbf{u}, \Lambda f)$$

Modelo Fatorial

Modelo Fatorial

Seja $\mathbf{X} = (X_1, \dots, X_p)' \sim (\mu, \Sigma)$. Dizemos que o modelo fatorial (com k fatores) de \mathbf{X} acontece se podemos escrever

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

Modelo Fatorial

Seja $\mathbf{X} = (X_1, \dots, X_p)' \sim (\mu, \Sigma)$. Dizemos que o modelo fatorial (com k fatores) de \mathbf{X} acontece se podemos escrever

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

- $\Lambda_{p \times k}$ é uma matriz de constantes,
- $f_{k \times 1}$ e $\mathbf{u}_{p \times 1}$ são vetores aleatórios.

Modelo Fatorial

Seja $\mathbf{X} = (X_1, \dots, X_p)' \sim (\mu, \Sigma)$. Dizemos que o modelo fatorial (com k fatores) de \mathbf{X} acontece se podemos escrever

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

- $\Lambda_{p \times k}$ é uma matriz de constantes,
- $f_{k \times 1}$ e $\mathbf{u}_{p \times 1}$ são vetores aleatórios.

Os elementos de f são chamados *fatores comuns* (ou simplesmente *fatores*) e os elementos de \mathbf{u} chamados de *fatores específicos*, *fatores únicos* ou *fatores idiossincráticos*.

Modelo Fatorial

Seja $\mathbf{X} = (X_1, \dots, X_p)' \sim (\mu, \Sigma)$. Dizemos que o modelo fatorial (com k fatores) de \mathbf{X} acontece se podemos escrever

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

- $\Lambda_{p \times k}$ é uma matriz de constantes,
- $f_{k \times 1}$ e $\mathbf{u}_{p \times 1}$ são vetores aleatórios.

Os elementos de f são chamados *fatores comuns* (ou simplesmente *fatores*) e os elementos de \mathbf{u} chamados de *fatores específicos*, *fatores únicos* ou *fatores idiossincráticos*.

O modelo é construído sob algumas suposições, as quais são apresentadas a seguir:

Modelo Fatorial: Suposições

- $\mathbb{E}(f) = 0$ e $\mathbb{V}(f) = \mathbf{I}$,
- $\mathbb{E}(\mathbf{u}) = 0$, $\text{Cov}(u_i, u_j) = 0$ e $\text{Cov}(f, \mathbf{u}) = 0$
- Consequentemente, $\mathbb{V}(u) = \mathbf{\Psi} = \text{Diag}\{\psi_1, \dots, \psi_p\}$

Modelo Fatorial: Suposições

- $\mathbb{E}(f) = 0$ e $\mathbb{V}(f) = \mathbf{I}$,
- $\mathbb{E}(\mathbf{u}) = 0$, $\text{Cov}(u_i, u_j) = 0$ e $\text{Cov}(f, \mathbf{u}) = 0$
- Consequentemente, $\mathbb{V}(u) = \mathbf{\Psi} = \text{Diag}\{\psi_1, \dots, \psi_p\}$

Os fatores comuns são não correlacionados (entre eles mesmos e com os fatores idiossincráticos), têm média zero e variância um.

Modelo Fatorial: Suposições

- $\mathbb{E}(f) = 0$ e $\mathbb{V}(f) = \mathbf{I}$,
- $\mathbb{E}(\mathbf{u}) = 0$, $\text{Cov}(u_i, u_j) = 0$ e $\text{Cov}(f, \mathbf{u}) = 0$
- Consequentemente, $\mathbb{V}(\mathbf{u}) = \mathbf{\Psi} = \text{Diag}\{\psi_1, \dots, \psi_p\}$

Os fatores comuns são não correlacionados (entre eles mesmos e com os fatores idiossincráticos), têm média zero e variância um.

- Outra suposição às vezes utilizada é que tanto f quanto \mathbf{u} tem distribuição Normal multivariada.

Modelo Fatorial

Modelo Fatorial: $\mathbf{X} = \mu + \Lambda \mathbf{f} + \mathbf{u}$,

Pode-se obter facilmente que $X_i = \mu_i + \sum_{j=1}^k \lambda_{ij} f_{ij} + u_i, \quad i = 1, \dots, p.$

Modelo Fatorial

Modelo Fatorial: $\mathbf{X} = \mu + \Lambda \mathbf{f} + \mathbf{u}$,

Pode-se obter facilmente que $X_i = \mu_i + \sum_{j=1}^k \lambda_{ij} f_{ij} + u_i$, $i = 1, \dots, p$.

Assim, $\mathbb{V}(X_i) = \sigma_i^2 = \sum_{j=1}^k \lambda_{ij}^2 + \psi_i^2$.

Modelo Fatorial

Modelo Fatorial: $\mathbf{X} = \mu + \Lambda \mathbf{f} + \mathbf{u}$,

Pode-se obter facilmente que $X_i = \mu_i + \sum_{j=1}^k \lambda_{ij} f_{ij} + u_i$, $i = 1, \dots, p$.

Assim, $\mathbb{V}(X_i) = \sigma_i^2 = \sum_{j=1}^k \lambda_{ij}^2 + \psi_i^2$.

- $\sum_{j=1}^k \lambda_{ij}^2$, denotada usualmente por h_i^2 , é chamada de *comunalidade* (variância comum) e representa a variância de X_i que é explicada pelos *fatores comuns*.
- ψ_i^2 é chamada de *variância específica*, representa a variabilidade de X_i que não é explicada pelos *fatores comuns*.

Modelo Fatorial

Modelo Fatorial: $\mathbf{X} = \mu + \Lambda f + \mathbf{u},$

Modelo Fatorial

$$\text{Modelo Fatorial: } \mathbf{X} = \mu + \Lambda f + \mathbf{u},$$

Se o modelo fatorial acontece, então $\mathbb{V}(\mathbf{X})$, denotada por Σ é dada por

$$\mathbb{V}(\mathbf{X}) = \Sigma = \Lambda\Lambda' + \Psi \quad (1)$$

O contrário também é válido. Se (1) acontece, então o modelo fatorial acontece para \mathbf{X} .

Modelo Fatorial

$$\text{Cov}(\mathbf{X}, f) = \Lambda$$

Modelo Fatorial

$$\mathbb{C}ov(\mathbf{X}, f) = \Lambda$$

$$\mathbb{C}ov(\mathbf{X}, f) = \mathbb{C}ov(\mu + \Lambda f + \mathbf{u}, f) \quad (2)$$

$$= \Lambda \underbrace{\mathbb{C}ov(f, f)}_I + \underbrace{\mathbb{C}ov(\mathbf{u}, f)}_0 \quad (3)$$

$$= \Lambda \quad (4)$$

Modelo Fatorial: Invarância

Seja $C = \text{diag}\{c_1, \dots, c_p\}$, o que acontece se mudamos a escala de \mathbf{X} para $\mathbf{Y} = \mathbf{CX}$?

Modelo Fatorial: Invarância

Seja $C = \text{diag}\{c_1, \dots, c_p\}$, o que acontece se mudamos a escala de \mathbf{X} para $\mathbf{Y} = C\mathbf{X}$?

Se o modelo fatorial acontece para \mathbf{X} , temos que

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

Modelo Fatorial: Invarância

Seja $C = \text{diag}\{c_1, \dots, c_p\}$, o que acontece se mudamos a escala de \mathbf{X} para $\mathbf{Y} = C\mathbf{X}$?

Se o modelo fatorial acontece para \mathbf{X} , temos que

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

Então,

- $\mathbf{Y} = C\mathbf{X} = \underbrace{C\mu}_{\mu_y} + \underbrace{C\Lambda}_{\Lambda_y} f + \underbrace{C\mathbf{u}}_{\mathbf{u}_y}$
- $\mathbb{V}(\mathbf{Y}) = \mathbb{V}(C\mathbf{X}) = C\mathbb{V}(\mathbf{X})C' = C[\Lambda\Lambda' + \Psi]C' = \underbrace{C\Lambda}_{\Lambda_y} \underbrace{\Lambda'C'}_{\Lambda'_y} + \underbrace{C\Psi C'}_{\Psi_{u_y}}$

Modelo Fatorial: Invarância

Seja $C = \text{diag}\{c_1, \dots, c_p\}$, o que acontece se mudamos a escala de \mathbf{X} para $\mathbf{Y} = C\mathbf{X}$?

Se o modelo fatorial acontece para \mathbf{X} , temos que

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u}$$

Então,

- $\mathbf{Y} = C\mathbf{X} = \underbrace{C\mu}_{\mu_y} + \underbrace{C\Lambda}_{\Lambda_y} f + \underbrace{C\mathbf{u}}_{\mathbf{u}_y}$
- $\mathbb{V}(\mathbf{Y}) = \mathbb{V}(C\mathbf{X}) = C\mathbb{V}(\mathbf{X})C' = C[\Lambda\Lambda' + \Psi]C' = \underbrace{C\Lambda}_{\Lambda_y} \underbrace{\Lambda' C'}_{\Lambda'_y} + \underbrace{C\Psi C'}_{\Psi_{u_y}}$

O modelo fatorial também acontece para \mathbf{Y} , tem matriz de cargas fatoriais dada por $\Lambda_y = C\Lambda$, variância específica $\Psi_{u_y} = C\Psi C$ e fator f .

Modelo Fatorial: Não unicidade das cargas fatoriais

As cargas fatoriais **não** são únicas!

Modelo Fatorial: Não unicidade das cargas fatoriais

As cargas fatoriais **não** são únicas!

Seja o modelo fatorial para \mathbf{X}

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u},$$

e seja G uma matriz ortonormal qualquer. Então,

$$\mathbf{X} = \mu + \Lambda G(G'f) + \mathbf{u}.$$

Modelo Fatorial: Não unicidade das cargas fatoriais

As cargas fatoriais **não** são únicas!

Seja o modelo fatorial para \mathbf{X}

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u},$$

e seja G uma matriz ortonormal qualquer. Então,

$$\mathbf{X} = \mu + \Lambda G(G'f) + \mathbf{u}.$$

- Se f e Λ são os fatores e as cargas fatoriais para \mathbf{X} , então $G'f$ e ΛG também são.

Modelo Fatorial: Não unicidade das cargas fatoriais

As cargas fatoriais **não** são únicas!

Seja o modelo fatorial para \mathbf{X}

$$\mathbf{X} = \mu + \Lambda f + \mathbf{u},$$

e seja G uma matriz ortonormal qualquer. Então,


$$\mathbf{X} = \mu + \Lambda G(G'f) + \mathbf{u}.$$

- Se f e Λ são os fatores e as cargas fatoriais para \mathbf{X} , então $G'f$ e ΛG também são.
- **Isto é bom ou ruim?**

Modelo Fatorial: Não unicidade das cargas fatoriais

Pros:

- Premultiplicar f por uma matriz ortogonal corresponde a uma rotação do sistema de coordenadas.
- A direção do primeiro eixo será dada pela primeira linha da matriz ortogonal.
- Escolher uma rotação apropriadas resultará em uma matriz de cargas ΛG que é **mais facil de interpretar!**



Modelo Fatorial: Não unicidade das cargas fatoriais



Contras:

- Desde um ponto de vista numérico, a não unicidade é um problema.
- Temos que encontrar matrizes Λ e Ψ tais que $\Sigma = \Lambda\Lambda' + \Psi$. Infelizmente numericamente isto não é tão simples devido à multiplicidade da solução.

O problema pode ser contornado impondo restrições para obter uma única solução à decomposição (e depois dessa solução podemos tomar vantagem das rotações).

Modelo Fatorial: Não unicidade das cargas fatoriais

Quais restrições vamos a impor para eliminar o problema da não unicidade?

Modelo Fatorial: Não unicidade das cargas fatoriais

Quais restrições vamos a impor para eliminar o problema da não unicidade?

$$\Lambda' \Psi^{-1} \Lambda \quad \text{ou} \quad \Lambda' \mathbf{D}^{-1} \Lambda \quad \text{ser diagonal.} \quad (5)$$

Modelo Fatorial: Não unicidade das cargas fatoriais

Quais restrições vamos a impor para eliminar o problema da não unicidade?

$$\Lambda' \Psi^{-1} \Lambda \quad \text{ou} \quad \Lambda' \mathbf{D}^{-1} \Lambda \quad \text{ser diagonal.} \quad (5)$$

- Note que Σ tem $p(p+1)/2$ parametros a serem estimados.
- Por outro lado $\Lambda' \Lambda + \Psi$ tem $pk + p$ parametros a serem estimados (pk vindo de $\Lambda_{p \times k}$ e p vindos de Ψ).
- (5) introduze $k(k-1)/2$ restrições.
- Assim, o número de graus de liberdade do modelo fatorial é

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

Modelo Fatorial: Não unicidade das cargas fatoriais

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

- Se $d < 0$, o modelo é indeterminado.

Modelo Fatorial: Não unicidade das cargas fatoriais

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

- **Se** $d < 0$, o modelo é indeterminado. (isto significa que o número de parâmetros do modelo fatorial é maior do que o número de parâmetros do modelo original. Reduzir k pode ajudar).

Modelo Fatorial: Não unicidade das cargas fatoriais

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

- **Se** $d < 0$, o modelo é indeterminado. (isto significa que o número de parâmetros do modelo fatorial é maior do que o número de parâmetros do modelo original. Reduzir k pode ajudar).
- **Se** $d = 0$, o modelo tem solução única (exceto, é claro, pelas rotações).

Modelo Fatorial: Não unicidade das cargas fatoriais

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

- **Se** $d < 0$, o modelo é indeterminado. (isto significa que o número de parâmetros do modelo fatorial é maior do que o número de parâmetros do modelo original. Reduzir k pode ajudar).
- **Se** $d = 0$, o modelo tem solução única (exceto, é claro, pelas rotações).
- **Se** $d > 0$ (o que mais acontece na prática), temos mais equações do que parâmetros e não existe uma solução exata

Modelo Fatorial: Não unicidade das cargas fatoriais

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

- **Se** $d < 0$, o modelo é indeterminado. (isto significa que o número de parâmetros do modelo fatorial é maior do que o número de parâmetros do modelo original. Reduzir k pode ajudar).
- **Se** $d = 0$, o modelo tem solução única (exceto, é claro, pelas rotações).
- **Se** $d > 0$ (o que mais acontece na prática), temos mais equações do que parâmetros e não existe uma solução exata (nestes casos, soluções aproximadas são utilizadas).

Modelo Fatorial: Não unicidade das cargas fatoriais

$$d = \frac{1}{2}p(p+1) - [(pk + p) - \frac{1}{2}k(k-1)] = \frac{1}{2}(p-k)^2 - \frac{1}{2}(p+k).$$

- **Se** $d < 0$, o modelo é indeterminado. (isto significa que o número de parâmetros do modelo fatorial é maior do que o número de parâmetros do modelo original. Reduzir k pode ajudar).
- **Se** $d = 0$, o modelo tem solução única (exceto, é claro, pelas rotações).
- **Se** $d > 0$ (o que mais acontece na prática), temos mais equações do que parâmetros e não existe uma solução exata (nestes casos, soluções aproximadas são utilizadas).

Para pensar: Se tivermos $p = 5$ variáveis, utilizaria $k = 3$ fatores?

Modelo Fatorial: Não unicidade das cargas fatoriais

Exemplo 1:

Suponha $p = 2$, $k = 1$ e seja

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = \Lambda\Lambda' + \Psi = \begin{pmatrix} \lambda_1^2 + \psi_{11} & \lambda_1\lambda_2 \\ \lambda_1\lambda_2 & \lambda_2^2 + \psi_{22} \end{pmatrix}$$

Modelo Fatorial: Não unicidade das cargas fatoriais

Exemplo 1:

Suponha $p = 2$, $k = 1$ e seja

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = \Lambda\Lambda' + \Psi = \begin{pmatrix} \lambda_1^2 + \psi_{11} & \lambda_1\lambda_2 \\ \lambda_1\lambda_2 & \lambda_2^2 + \psi_{22} \end{pmatrix}$$

- $1 = \lambda_1^2 + \psi_{11}$, $\rho = \lambda_1\lambda_2$ e $1 = \lambda_2^2 + \psi_{22}$.

Modelo Fatorial: Não unicidade das cargas fatoriais

Exemplo 1:

Suponha $p = 2$, $k = 1$ e seja

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = \Lambda\Lambda' + \Psi = \begin{pmatrix} \lambda_1^2 + \psi_{11} & \lambda_1\lambda_2 \\ \lambda_1\lambda_2 & \lambda_2^2 + \psi_{22} \end{pmatrix}$$

- $1 = \lambda_1^2 + \psi_{11}$, $\rho = \lambda_1\lambda_2$ e $1 = \lambda_2^2 + \psi_{22}$.
- $\lambda_2 = \rho/\lambda_1$, $\psi_{11} = 1 - \lambda_1^2$ e $\psi_{22} = 1 - (\rho/\lambda_1)^2$

Modelo Fatorial: Não unicidade das cargas fatoriais

Exemplo 1:

Suponha $p = 2$, $k = 1$ e seja

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = \Lambda\Lambda' + \Psi = \begin{pmatrix} \lambda_1^2 + \psi_{11} & \lambda_1\lambda_2 \\ \lambda_1\lambda_2 & \lambda_2^2 + \psi_{22} \end{pmatrix}$$

- $1 = \lambda_1^2 + \psi_{11}$, $\rho = \lambda_1\lambda_2$ e $1 = \lambda_2^2 + \psi_{22}$.
- $\lambda_2 = \rho/\lambda_1$, $\psi_{11} = 1 - \lambda_1^2$ e $\psi_{22} = 1 - (\rho/\lambda_1)^2$

Infinitas soluções! (o sistema é indeterminado)

Modelo Fatorial: Não unicidade das cargas fatoriais

Exemplo 2:

Suponha $p = 3$, $k = 1$ e seja

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{pmatrix} = \begin{pmatrix} \lambda_1^2 + \psi_{11} & \lambda_1 \lambda_2 & \lambda_1 \lambda_3 \\ \lambda_1 \lambda_2 & \lambda_2^2 + \psi_{22} & \lambda_2 \lambda_3 \\ \lambda_1 \lambda_3 & \lambda_2 \lambda_3 & \lambda_3^2 + \psi_{33} \end{pmatrix}$$

Modelo Fatorial: Não unicidade das cargas fatoriais

Exemplo 2:

Suponha $p = 3$, $k = 1$ e seja

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{pmatrix} = \begin{pmatrix} \lambda_1^2 + \psi_{11} & \lambda_1 \lambda_2 & \lambda_1 \lambda_3 \\ \lambda_1 \lambda_2 & \lambda_2^2 + \psi_{22} & \lambda_2 \lambda_3 \\ \lambda_1 \lambda_3 & \lambda_2 \lambda_3 & \lambda_3^2 + \psi_{33} \end{pmatrix}$$

Então,

- $\lambda_1^2 = \frac{\sigma_{12}\sigma_{13}}{\sigma_{23}}$, $\lambda_2^2 = \frac{\sigma_{12}\sigma_{23}}{\sigma_{13}}$ e $\lambda_3^2 = \frac{\sigma_{13}\sigma_{23}}{\sigma_{12}}$
- $\psi_{11} = \sigma_{11} - \lambda_1^2$, $\psi_{22} = \sigma_{22} - \lambda_2^2$ e $\psi_{33} = \sigma_{33} - \lambda_3^2$

Modelo Fatorial: Não unicidade das cargas fatoriais

No caso anterior, utilizemos

$$\Sigma = \begin{pmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{pmatrix}$$

Modelo Fatorial: Não unicidade das cargas fatoriais

No caso anterior, utilizemos

$$\Sigma = \begin{pmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{pmatrix}$$

Então a solução - $\lambda_1^2 = \frac{\sigma_{12}\sigma_{13}}{\sigma_{23}}$, $\lambda_2^2 = \frac{\sigma_{12}\sigma_{23}}{\sigma_{13}}$ e $\lambda_3^2 = \frac{\sigma_{13}\sigma_{23}}{\sigma_{12}}$ -

$\psi_{11} = \sigma_{11} - \lambda_1^2$, $\psi_{22} = \sigma_{22} - \lambda_2^2$ e $\psi_{33} = \sigma_{33} - \lambda_3^2$

nos levará a: $\psi_{11} = 1 - \frac{0.9 \times 0.7}{0.4} = -0.575$

Modelo Fatorial: Não unicidade das cargas fatoriais

No caso anterior, utilizemos

$$\Sigma = \begin{pmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{pmatrix}$$

Então a solução - $\lambda_1^2 = \frac{\sigma_{12}\sigma_{13}}{\sigma_{23}}$, $\lambda_2^2 = \frac{\sigma_{12}\sigma_{23}}{\sigma_{13}}$ e $\lambda_3^2 = \frac{\sigma_{13}\sigma_{23}}{\sigma_{12}}$ -

$\psi_{11} = \sigma_{11} - \lambda_1^2$, $\psi_{22} = \sigma_{22} - \lambda_2^2$ e $\psi_{33} = \sigma_{33} - \lambda_3^2$

nos levará a: $\psi_{11} = 1 - \frac{0.9 \times 0.7}{0.4} = -0.575$

Variância negativa?

Modelo Fatorial: Não unicidade das cargas fatoriais

No caso anterior, utilizemos

$$\Sigma = \begin{pmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{pmatrix}$$

Então a solução - $\lambda_1^2 = \frac{\sigma_{12}\sigma_{13}}{\sigma_{23}}$, $\lambda_2^2 = \frac{\sigma_{12}\sigma_{23}}{\sigma_{13}}$ e $\lambda_3^2 = \frac{\sigma_{13}\sigma_{23}}{\sigma_{12}}$ -

$\psi_{11} = \sigma_{11} - \lambda_1^2$, $\psi_{22} = \sigma_{22} - \lambda_2^2$ e $\psi_{33} = \sigma_{33} - \lambda_3^2$

nos levará a: $\psi_{11} = 1 - \frac{0.9 \times 0.7}{0.4} = -0.575$

Variância negativa? Cuidado! mesmo quando $d = 0$, a solução única pode apresentar inconsistências estatísticas.

Estimação

Estimação

Na pratica, Σ , Λ , f , Ψ são todos desconhecidos (e precisam ser estimados).

Estimação

Na pratica, Σ , Λ , f , Ψ são todos desconhecidos (e precisam ser estimados).

Assim, temos que achar $\hat{\Lambda}$ e $\hat{\Psi}$ tais que

$$\mathbf{S} = \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$$

,

Estimação

Na pratica, Σ , Λ , f , Ψ são todos desconhecidos (e precisam ser estimados).

Assim, temos que achar $\hat{\Lambda}$ e $\hat{\Psi}$ tais que

$$\mathbf{S} = \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$$

,

Consequentemente, $\hat{h}_i^2 = \sum_{j=1}^k \hat{\lambda}_{ij}$

Estimação

Na pratica, Σ , Λ , f , Ψ são todos desconhecidos (e precisam ser estimados).

Assim, temos que achar $\hat{\Lambda}$ e $\hat{\Psi}$ tais que

$$\mathbf{S} = \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$$

,

Consequentemente, $\hat{h}_i^2 = \sum_{j=1}^k \hat{\lambda}_{ij}$

- Se $d = 0$, existe solução exata.
- Se $d > 0$, temos que achar $\hat{\Lambda}$ e $\hat{\Psi}$ tais que $\mathbf{S} \approx \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$.

Estimação

Na prática, Σ , Λ , f , Ψ são todos desconhecidos (e precisam ser estimados).

Assim, temos que achar $\hat{\Lambda}$ e $\hat{\Psi}$ tais que

$$\mathbf{S} = \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$$

,

Consequentemente, $\hat{h}_i^2 = \sum_{j=1}^k \hat{\lambda}_{ij}^2$

- Se $d = 0$, existe solução exata.
- Se $d > 0$, temos que achar $\hat{\Lambda}$ e $\hat{\Psi}$ tais que $\mathbf{S} \approx \hat{\Lambda}\hat{\Lambda}' + \hat{\Psi}$.

Na próxima aula aprenderemos métodos para fazer a estimação.

Referências

Referências

- Härdle, W. K., & Simar, L. (2019). Applied Multivariate Statistical Analysis. Fifth Edition. Springer Nature. Capítulo 12.
- Mardia, K. V., Kent, J. T., & Bibby, J. M. (1979). Multivariate Analysis. Academic Press. Capítulo 9.
- Peña, D. (2002). Análisis de Datos Multivariantes. Mc Graw Hill. Capítulo 12.